CUDA 算子优化及 GPU 显存架构学习笔记

1. GPU 内存层次结构与特点

在进行算子级别的底层优化时，理解内存层次结构是第一步。

- **Global Memory (全局内存)**: 容量最大，但延迟极高（几百个时钟周期）。优化重点是实现合并访问（Coalesced Memory Access），尽量让相邻线程访问相邻地址。
- **Shared Memory (共享内存)**: 位于 SM 内部，延迟极低（接近寄存器）。常用于 Block 内线程块的数据共享和缓存。使用时需高度注意避免 Bank Conflict（存储体冲突）。
- **Registers (寄存器)**: 速度最快，但数量有限。过多的寄存器使用会导致 Register Spilling（溢出到 Local Memory），这会严重拖慢运行性能。

2. 矩阵乘法（GEMM）算子优化实践

矩阵乘法是深度学习的底层核心，常规优化思路如下：

1. **Tiling (分块处理)**: 将大矩阵划分为适应 Shared Memory 大小的小块（Tile），从而减少对 Global Memory 的重复读取。
2. **Double Buffering (双缓冲)**: 利用预取指令（Prefetching），在计算当前块数据的同时，将下一块数据提前加载到寄存器中，掩盖内存延迟。
3. **Warp 级别优化**: 利用 Warp Shuffle 指令在寄存器层面直接进行数据交换，进一步压榨硬件性能。

3. 常见性能瓶颈排查 (Profiling)

- 推荐使用 Nsight Compute 查看 `Compute Workload Analysis` 和 `Memory Workload Analysis` 面板。
- 如果 `Memory Bound` 指标过高，优先优化访存模式；如果 `Compute Bound` 指标过高，则需要检查指令吞吐量和分支发散（Branch Divergence）问题。