轻量级文档解析与检索服务 API 说明文档

1. 服务概述

本微服务主要负责接收各种格式的文档（PDF, Word, Markdown），将其进行结构化解析（Parsing）、文本分块（Chunking），并调用 Embedding 模型生成向量化数据存入 Vector DB。这是底层 RAG 链路的核心数据接入层。

2. 系统依赖与选型

- **文档解析组件**: PyMuPDF / Unstructured
- **向量数据库**: Milvus / Qdrant (生产环境推荐集群部署)
- **Embedding 模型**: BGE-M3 (支持多语言及长文本)

3. 核心 API 接口说明

3.1 提交文档解析任务

- **接口路径**: `/api/v1/document/ingest`
- **请求方式**: `POST`
- **请求头 (Headers)**:
  - `Authorization: Bearer <Token>`
  - `Content-Type: multipart/form-data`
- **请求参数**:
  - `file`: 待处理的文件对象 (必填)
  - `chunk_size`: 切分块大小，默认 500 (选填)
  - `chunk_overlap`: 块重叠大小，默认 50 (选填)
- **响应示例**:

```
{
  "status": "success",
  "task_id": "doc_9527_abc",
  "message": "文档已进入异步解析队列，请轮询状态接口"
}
```